#### 31026 - INTRODUCTION À L'INTELLIGENCE ARTIFICIELLE ET AUX DATA SCIENCES

Vincent Guigue Christophe Marsala

Sorbonne Université







#### Feedback semaine précédente



#### UE IADS = triple difficulté

- Dimension mathématique et statistique
- Dimension algorithmique
- Dimension implémentation

#### Plan statistique:

- Définir une gaussienne, en 1D, en 2D
- Travailler sur une multinomiale
- Générer des points tirés selon une gaussienne en 2D

#### Feedback semaine précédente



#### UE IADS = triple difficulté

- Dimension mathématique et statistique
- Dimension algorithmique
- Dimension implémentation

#### Plan algorithmique:

- Gérer les itérations de l'algorithme du perceptron
- Algorithmes full gradient / batch / purement stochastique
- Notion d'*epoch*
- Détection de la convergence dans une descente de gradient

#### Feedback semaine précédente



#### UE IADS = triple difficulté

- Dimension mathématique et statistique
- Dimension algorithmique
- Dimension implémentation

#### Plan implémentation :

- A-t-on besoin de fournir les dimensions des entrées/sorties pour la création du classifieur?
- Quand initialiser les paramètres du classifieur?
- Comment gérer les epochs (solutions internes & externes)

# Visualisation



■ InfoVis = Information Visualization

The use of computer-supported interactive, visual representation of abstract data to amplify cognition Card, Mackinlay & Shneiderman

- DataVis = Data Visualization
- Deux problèmes extrêmement importants dans la data science
- Deux problèmes peu abordés...

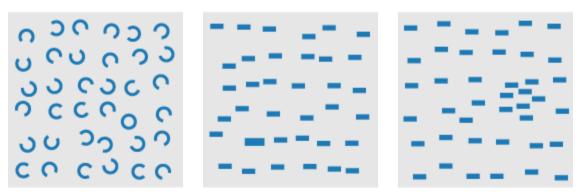
Référence utile : Cours de F. Rossi http://apiacoa.org/teaching/visualization/index.fr.html

⇒ Lien avec l'apprentissage statistique : Quelles méthodes permettent de trouver automatiquement de bonnes visualisations des données ?

#### Humain = machine visuelle très perfectionnée



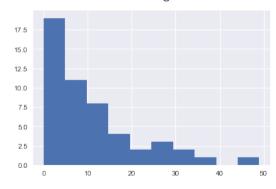
- Extraction de caractéristiques de base en 200ms
- Possibilités d'analyse de densité / détection d'anomalie très rapide



https://www.csc2.ncsu.edu/faculty/healey/PP/index.html

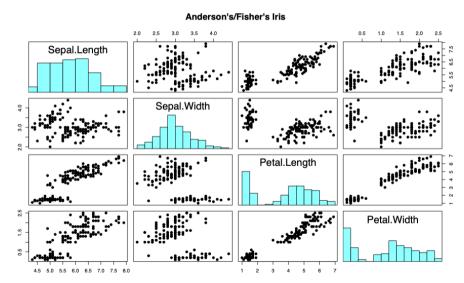


- Focus sur une dimension  $X_i$ 
  - N Observations x<sub>ij</sub>
- Solution pour la visualisation du contenu : l'histogramme





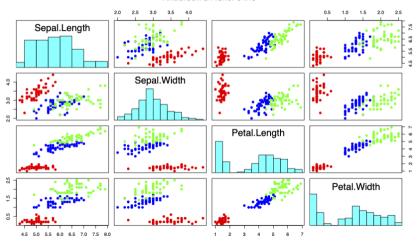
Données orgininales = Iris, 4D : comment visualiser?  $\Rightarrow$  Scatter plot





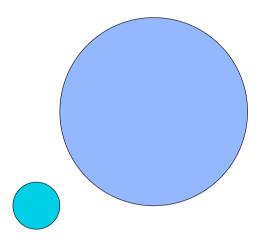
Données orgininales = Iris, 4D : comment visualiser? ⇒ Scatter plot

#### Anderson's/Fisher's Iris



Avec les informations de classes





Please write down your estimation of the ratio of the areas of those disks.

#### Limites humaines





Please write down your estimation of the ratio of the lengths of those bars.

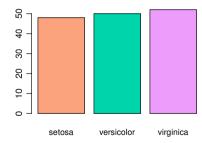


#### Another visual abstraction

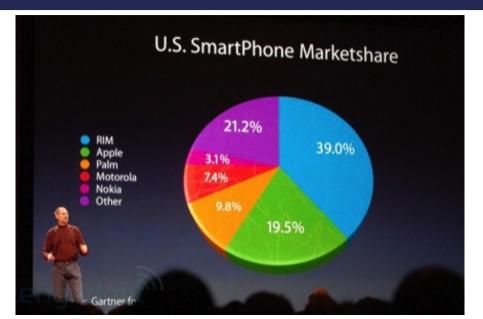
Using the same counting data, replace the  ${\it Q}$  pie slices by  ${\it Q}$  bars with length/height proportional to  ${\it N}_{\it q}$ 

#### And the views are

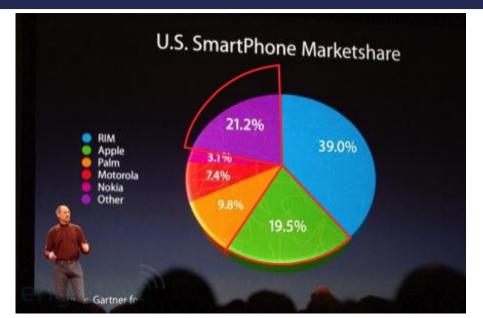












## Malédiction de la dimensionnalité

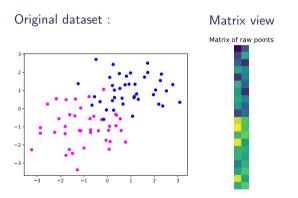
#### Objectifs de la visualisation de données



- 1 Eliminer du bruit
  - Labélisation
  - captation
  - ⇒ Transformation légère
- 2 Comprendre des modes de fonctionnement des données
  - Zones de densités
  - Feature engineering
  - $\Rightarrow$  Transformation avancée



A classical toy example to illustrate the curse of dimensionality :



Distance matrix

Matrix of distance between points

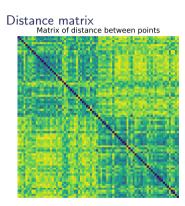
Easy problem / classes are clearly separated



A classical toy example to illustrate the curse of dimensionality :

Original dataset: Matrix view Matrix of raw points -2 -3

Adding some noisy dimensions in the dataset





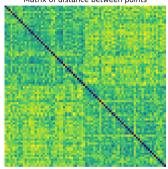
A classical toy example to illustrate the curse of dimensionality :

Original dataset : Matrix view

Matrix of raw points

Distance matrix

Matrix of distance between points

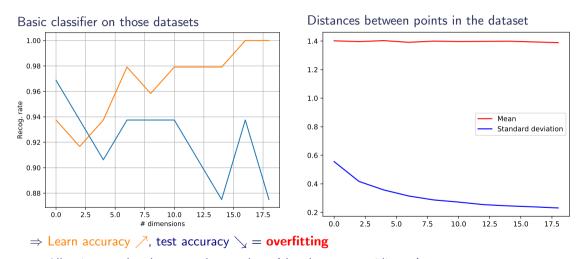


Adding more noisy dimensions in the dataset

 $\Rightarrow$  Euclidian distance is very sensitive to the dimensionality issue



A classical toy example to illustrate the curse of dimensionality :



 $\Rightarrow$  All points tend to lay on an hypersphere (they become equidistant)

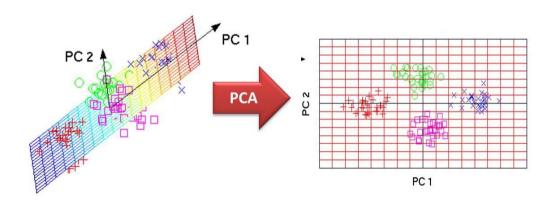
### Transformations avancées

#### ACP : analyse en composantes principales



ACP (PCA) = outil de base pour

- La visualisation de données en grande dimension
- 2 La réduction de la dimension et du bruit



#### ACP: analyse en composantes principales

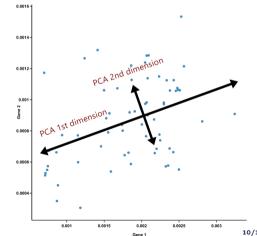


ACP (PCA) = outil de base pour

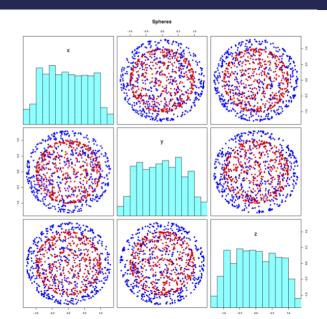
- La visualisation de données en grande dimension
- La réduction de la dimension et du bruit

ldée : trouver des axes qui maximise la variance ⇒ projeter sur ces axes

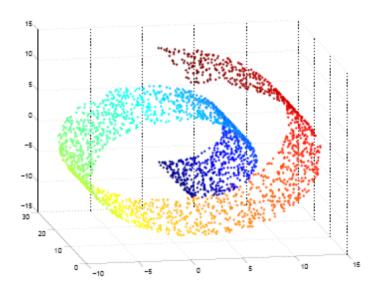
- Transformation non supervisée
- Transformation applicable sur de nouveaux points
  - $X \in \mathbb{R}^{N \times d}$
  - **2** ACP sur  $X^TX \in \mathbb{R}^{d \times d}$
  - **3** Récupétation de  $\{V_i \in \mathbb{R}^d, \lambda_i \in \mathbb{R}_+\}_{i=1,\dots,d}$
  - d Axes de projection  $V_i$ ... associés à leur force d'explication  $\lambda_i$
  - 5 Utilisation des Vi sur les données de test



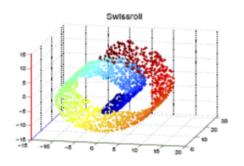


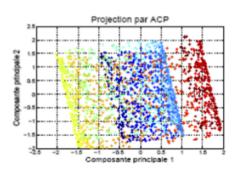






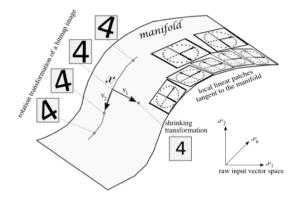






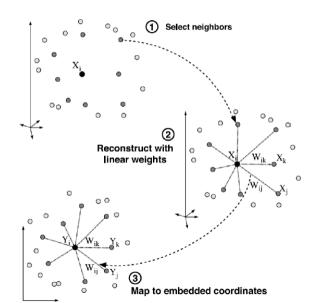


Idée : Les données sont organisées selon une variété



#### LLE: local linear embedding





#### MDS: multi-dimensional scaling

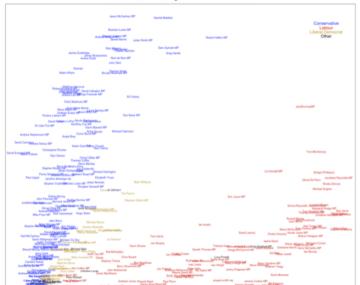


	Atlanta (1)	Boston (2)	Cincinnati (3)	Columbus (4)	Dallas (5)	Indianapolis (6)	Little Rock (7)	Los Angeles (8)	Memphis (9)	St. Louis (10)	Spokane (11)	Tampa (12)
(1)	0											
(2)	1068	0										
(3)	461	867	0									
(4)	549	769	107	0								
(5)	805	1819	943	1050	0							
(6)	508	941	108	172	882	0						
(7)	505	1494	618	725	325	562	0					
(8)	2197	3052	2186	2245	1403	2080	1701	0				
(9)	366	1355	502	586	464	436	137	1831	0			
(10)	558	1178	338	409	645	234	353	1848	294	0		
(11)	2467	2747	2067	2131	1891	1959	1988	1227	2042	1820	0	
(12)	467	1379	928	985	1077	975	912	2480	779	1016	2821	0

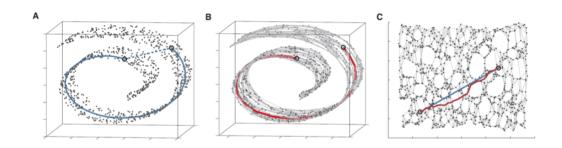




#### Two dimensional clustering of UK Members of Parliament









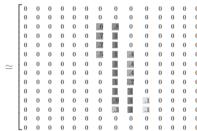
Step		
1	Construct neighborhood graph	Define the graph $G$ over all data points by connecting points $i$ and $j$ if [as measured by $d_X(i,j)$ ] they are closer than $\epsilon$ ( $\epsilon$ -Isomap), or if $i$ is one of the $K$ nearest neighbors of $j$ ( $K$ -Isomap). Set edge lengths equal to $d_X(i,j)$ .
2	Compute shortest paths	Initialize $d_G(i,j) = d_X(i,j)$ if $i,j$ are linked by an edge; $d_G(i,j) = \infty$ otherwise. Then for each value of $k = 1, 2, \ldots, N$ in turn, replace all entries $d_G(i,j)$ by $\min\{d_G(i,j), d_G(i,k) + d_G(k,j)\}$ . The matrix of final values $D_G = \{d_G(i,j)\}$ will contain the shortest path distances between all pairs of points in $G$ (16, 19).
3	Construct <i>d</i> -dimensional embedding	Let $\lambda_p$ be the $p$ -th eigenvalue (in decreasing order) of the matrix $\tau(D_G)$ (17), and $v_p'$ be the $i$ -th component of the $p$ -th eigenvector. Then set the $p$ -th component of the $d$ -dimensional coordinate vector $\mathbf{y}_i$ equal to $\sqrt{\lambda_p}v_p'$ .



Que se passe-t-il sur des données USPS ou MNIST ? 256/384 dimensions  $\Rightarrow 2D!$ 



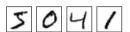




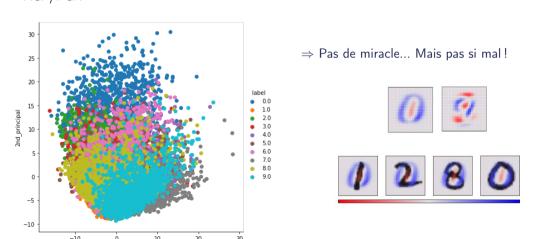
#### Sur USPS



Que se passe-t-il sur des données USPS ou MNIST ? 256/384 dimensions  $\Rightarrow 2D!$ 

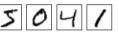


#### ACP/PCA

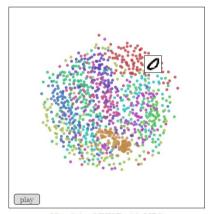




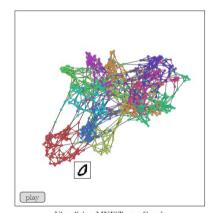
Que se passe-t-il sur des données USPS ou MNIST ? 256/384 dimensions  $\Rightarrow 2D!$ 



#### Projection non linéaire



Visualizing MNIST with MDS

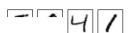


Visualizing MNIST as a Graph

#### Sur USPS



Que se passe-t-il sur des données USPS ou MNIST ? 256/384 dimensions  $\Rightarrow$ 



T-SNE

